

# Variational AutoEncoder


---

Hiroki Adachi

**Source code:** <https://github.com/hirokiadachi/VAE>



# 生成モデルとは



**CNN**  
(Convolutional Neural Networks)




Cat

**z**  
(Latent vector)



どうやって獲得する?




**CNN**  
(Convolutional Neural Networks)




# Autoencoder (AE)

- EncoderとDecoderによって構成
  - Encoder : 入力データの情報を低次元ベクトルへ埋め込む
  - Decoder : 低次元ベクトルを入力としてデータを復元
- 入力データを低次元ベクトルから再構成できるように学習
  - データを圧縮または復元するために適した重みパラメータを獲得
- 深層学習をベースとした識別や認識などのfine-tuningとして利用可能



**z**  
(Latent vector)



# AEの派生手法

- Sparse AE

- 活性化平均度によって潜在変数に関してスパース性能が改善
  - High sparseness : 再構成データがシンプルな表現になり, 数字がそのまま出力
  - Low sparseness : 潜在変数が様々な情報を含むため, 複雑なデータが復元される

- Denoising AE

- 欠落したデータを入力して, 補間するように学習することが可能
  - 入力データはガウスノイズ, 胡麻塩ノイズ, マスクなどの処理を施す

- Variational AE

- 変分推論を使用
  - 中間層で獲得する潜在変数が何かしらの確率密度関数 (PDF) に基づくように学習

# AEの派生手法

- Sparse AE

- 活性化平均度によって潜在変数に関してスパース性能が改善
  - High sparseness : 再構成データがシンプルな表現になる
  - Low sparseness : 潜在変数が様々な情報を含むため、複雑なデータが復元される

- Denoising AE


- 欠落したデータを入力して、保管するように学習することが可能
  - 入力データはガウスノイズ、胡麻塩ノイズ、マスクなどの処理を施す

- Variational AE

- 变分推論を使用
  - 中間層で獲得する潜在変数が何かしらの確率密度関数 (PDF) に基づくように学習


# Variational Autoencoder (VAE)

- 生成モデルという枠組みでAEを解釈した手法
  - ネットワークの構造はAEと似ている



VAE motivation: Maximising

$$p(x; \theta) = \int \frac{p(x|z; \theta)}{\text{posterior}} \frac{p(z; \theta)}{\text{prior}} dz$$




- 古典的または一般的
  - EM algorithm, MCMC (Markov Chain Monte Carlo)などを使用
- VAE
  - 従来とは異なる変分推論手法を使用
    - Evidence Lower Bound (ELBO)

# Evidence Lower Bound

$$p(x; \theta) = \int p(x|z; \theta)p(z; \theta)dz$$

↓

$$q(z|x; \phi)$$



- $p(z|x; \theta)$ は直接推定することは困難
  - 推定が困難な $p(z|x; \theta)$ の代わりに $q(z|x; \phi)$ を使用
  - KLを利用して分布の類似度を調査 :  $D_{KL}[q(z|x; \phi) || p(z|x; \theta)]$
- ↓
- 事後確率 ( $p(z|x; \theta)$ )を含むため計算ができない

# Evidence Lower Bound

$$\begin{aligned}
 D_{KL} [q(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}|\mathbf{x})] &= \int q(\mathbf{z}|\mathbf{x}) \log \frac{q(\mathbf{z}|\mathbf{x})}{p(\mathbf{z}|\mathbf{x})} d\mathbf{z} \\
 &= \int q(\mathbf{z}|\mathbf{x}) \left( \log q(\mathbf{z}|\mathbf{x}) - \log \frac{p(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p(\mathbf{x})} \right) d\mathbf{z} \\
 &= \log p(\mathbf{x}) + \int q(\mathbf{z}|\mathbf{x}) \left( \log \frac{q(\mathbf{z}|\mathbf{x})}{p(\mathbf{z})} - \log p(\mathbf{x}|\mathbf{z}) \right) d\mathbf{z} \\
 &= \log p(\mathbf{x}) + D_{KL} [q(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z})] - \int q(\mathbf{z}|\mathbf{x}) \log p(\mathbf{x}|\mathbf{z}) d\mathbf{z}
 \end{aligned}$$

Jensen's inequality

**ELBO**

**Bayes's rule**

$$p(\mathbf{z}|\mathbf{x}) = \frac{p(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p(\mathbf{x})}$$

$$p(\mathbf{x}|\mathbf{z}) = \frac{p(\mathbf{z}|\mathbf{x})p(\mathbf{x})}{p(\mathbf{z})}$$

# Kullback-Leibler Divergence

$$\log p(\mathbf{x}) \geq D_{KL} [q(\mathbf{z}|\mathbf{x}\|\mathbf{p}(\mathbf{z}))] - \int q(\mathbf{z}|\mathbf{x}) \log p(\mathbf{x}|\mathbf{z}) d\mathbf{z}$$


- $\mathbf{p}(\mathbf{z})$ は多変量正規分布を仮定
- $q(\mathbf{z}|\mathbf{x})$ は多変量正規分布 $\mathbf{p}(\mathbf{z})$ と近似させる

$$\begin{aligned} D_{KL} [q(\mathbf{z}|\mathbf{x})\|\mathbf{p}(\mathbf{z})] &= D_{KL} [N(\mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\Sigma})\|N(\mathbf{z}; \mathbf{0}, \mathbf{I})] \\ &= \frac{1}{2} \left[ \text{tr}(\boldsymbol{\Sigma}_1^{-1}) \boldsymbol{\Sigma}_0 + (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^T \boldsymbol{\Sigma}_1^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) - k + \log_e \frac{|\boldsymbol{\Sigma}_1|}{|\boldsymbol{\Sigma}_0|} \right] \\ &= \frac{1}{2} \left( \text{tr}(\boldsymbol{\Sigma}_0) + \boldsymbol{\mu}_0^T \boldsymbol{\mu}_0 - k - \log_e |\boldsymbol{\Sigma}_0| \right) \end{aligned}$$

多変量正規分布 (平均:  $\boldsymbol{\mu}$ , 共分散:  $\boldsymbol{\Sigma}$ )

$$N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^k |\boldsymbol{\Sigma}|}} \exp\left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right)$$

# Reparameterization Trick




# Reparameterization Trick



This situation cannot use back-propagation

# Reparameterization Trick



# Reparameterization Trick




Core idea of VAE based on NN



# VAEを動作させた結果


MPRG

training data



Reconstructed

training data



Reconstructed

